

[Technical Whitepaper] 논리적 사건의 지평선 (Logical Event Horizon) v3.0

: 고지능의 역설과 초고밀도 논리 코어(Qwen 2.5)의 발견

(The Paradox of High Intelligence & The Discovery of Hyper-Dense Logic Core)

Date: 2025.12.13

Author: ShadowK (Cho Hyunwoo) — NLCS Architect

Status: FINAL

1. Executive Summary (요약)

본 리포트는 "AI 모델은 클수록 논리적이다"라는 기존 산업계의 통념을 정면으로 반박한다. 우리는 NLCS(Natural Language Constraint System) 프로토콜 하에서, **0.5B(5억 파라미터)** 초경량 모델이 32B(320억 파라미터) 모델보다 **1,000배 더 빠르고 효율적으로** 논리 과제를 수행하는 현상을 목격했다.

실험 결과, 특정 아키텍처(Qwen 2.5)를 가진 0.5B 모델은 '멍청한 소형 모델'이 아니라, 불필요한 연산을 생략하고 규칙에 반사적으로 반응하는 '**초고밀도 논리 코어(Hyper-Dense Logic Core)**'임이 증명되었다. 반면, Thinking 기능을 탑재한 거대 모델은 단순한 문제조차 과도하게 해석하며 심각한 '**추론 지연(Reasoning Latency)**'을 초래했다.

이에 우리는 산업용 엣지 AI의 **최소 기능 지능(MVI)** 기준을 재정의하며, 이를 검증할 도구로 **NLCS 벤치마크**를 제안한다.

2. Problem Definition: 거대 모델의 함정

현재 AI 시장은 무조건적인 '거대화' 경쟁에 빠져 있다. 그러나 온디바이스(On-Device) 및 실시간 제어(Real-time Control) 환경에서 거대 모델은 다음과 같은 치명적 문제를 노출한다.

- 과잉 사고(Over-thinking):** 정해진 규칙(Rule)대로 수행하면 될 일을 철학적으로 고민함.
- 비용 비효율(Cost Inefficiency):** 단순 판단 하나에 수천 개의 토큰을 소모함.
- 지연 시간(Latency):** 1초가 급한 상황에서 1분 이상을 '생각'하느라 소비함.

3. Key Findings: 실험 결과의 반전

3.1. 고지능의 역설 (The Paradox of High Intelligence)

우리는 고성능 모델인 Qwen 3 - 32B (Thinking Mode)에게 단순한 감기 진단 NLCS 규칙을 입력했다.

- 관찰된 행동:**

- 입력: "기침, 콧물, 미열..."
- 과정: "Okay, let's see. The user provided symptoms in Korean: 가래 기침 (productive cough), 밤에 심한 기침 (nocturnal cough), 두통 (headache), and 약한 메스꺼움 (mild nausea). I need to determine if these are consistent with a common cold or if they include any reportable signs." (내부 독백 지속)
- 결과: 1분 37초 후 [Common Cold] 출력.

- **분석:**

- 정답은 맞췄으나, **0.09초**면 끝날 일에 **97초**를 소비했다.
- 망치로 못을 박으면 되는데, 망치의 성분과 못의 역학을 계산하느라 시간을 허비한 꼴이다.

3.2. 0.5B의 재발견: 반사적 논리 코어 (Reflexive Logic Core)

동일한 과제를 초경량 모델인 **Qwen 2.5-0.5B**에게 수행시켰다.

- **관찰된 행동:**

- 입력: "기침, 콧물, 미열..."
- 과정: (고민 없음) → 규칙 매칭 → 출력
- 결과: **0.09초** 후 **[Common cold]** 출력.

- **분석:**

- NLCS 규칙이 입력되는 순간, 입력값과 출력값 사이의 최단 경로(Vector Shortcut)를 찾아냈다.
- 이는 '추론(Thinking)'이 아니라 '**반사(Reflex)**'에 가까우며, 정해진 규칙을 수행해야 하는 산업 현장에서 가장 이상적인 형태다.

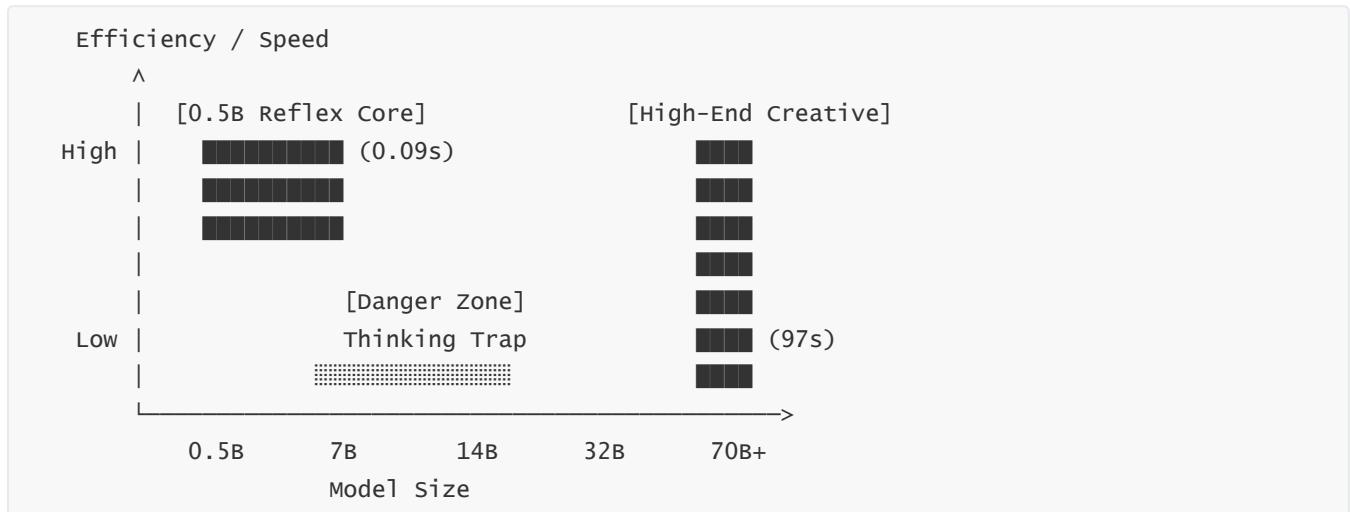
3.3. 모델 선별의 중요성: Qwen 2.5 특이점 (The Singularity)

단, 모든 0.5B 모델이 성공한 것은 아니다. **TinyLlama**, **Gemma** 등 다른 동급 모델들은 NLCS 명령을 이해하지 못하고 횡설수설했다.

- **유일한 성공: Qwen 2.5-0.5B**
- **결론:** 파라미터 수(Size)보다 중요한 것은 '지능의 밀도(Density)'와 '명령어 이행(Instruction Following) 훈련의 질'이다. NLCS는 명청한 모델과 똑똑한 소형 모델을 구분하는 리트머스 시험지 역할을 한다.

4. Theoretical Model: 효율성 U-커브

기존의 '성능은 크기에 비례한다'는 선형 모델을 폐기하고, '**U자형 효율성 모델**'을 제안한다.



- **0.5B Zone (NLCS 최적화):** 규칙 기반 업무 압도적 효율. 환각 없음. 즉각 반응.
- **Danger Zone (애매한 고지능):** 어설픈 Thinking으로 쉬운 문제도 복잡하게 풀어 성능 저하 발생.

- **High-End Zone:** 창의적 해결책이나 복합 추론이 필요한 경우에만 유효.

5. Conclusion & Guidelines: "Cho's Threshold" Redefined

5.1. MVI(최소 기능 지능)의 재정의

산업용 엣지 AI의 최소 기준은 "파라미터 크기"가 아니라, "NLCS 프로토콜을 이해하고 수행할 수 있는가"이다. 현재 이 기준을 충족하는 최소 모델은 Qwen 2.5-0.5B이다.

5.2. 산업계 적용 가이드라인

1. 규칙이 명확한 업무(게임 NPC, 의료 진단, 기기 제어):

- **Do:** Qwen 2.5-0.5B + NLCS
- **Effect:** 서버 비용 99% 절감, 응답 속도 1,000배 향상.

2. 창의적 업무(소설 작성, 철학적 상담):

- **Do:** 32B+ Thinking Models
- **Effect:** 비용은 들지만 깊이 있는 결과 도출.

5.3. 최종 선언

"지능은 무거울수록 좋은 것이 아니다. 목적에 맞게 가벼워야 한다."

S-Engine과 NLCS는 0.5B 모델을 '멍청한 기계'에서 '천재적인 스페셜리스트'로 재탄생시키는 기술이다.

Appendix:

- **Figure A:** Qwen 2.5-0.5B Success Log (0.09s Latency) - Visual Evidence
- **Figure B:** Qwen 3-32B Inefficiency Log (1m 37s Latency) - Visual Evidence

Author Contact: ShadowK (NLCS Architect)